Guía para la Generación del Grafo de Conocimiento HER2

Pipeline Completo con LLM por API y LangGraph

Proyecto DigPatho – Módulo de Conocimiento Clínico HER2
Versión: 1.0
Fecha: Abril 2026
Autor: H. Leonardo Rufiner – Instituto de Señales, Sistemas e Inteligencia Computacional

---

Tabla de Contenidos

1. Introducción y Motivación
2. Arquitectura General del Pipeline
3. Fuentes Documentales Integradas
4. Componentes del Pipeline
   - 4.1 Ingesta y Preprocesamiento de Documentos
   - 4.2 Extracción de Entidades y Relaciones mediante LLM
   - 4.3 Construcción del Grafo con LangGraph
   - 4.4 Serialización RDF/OWL y Almacenamiento
   - 4.5 Validación y Control de Calidad
5. Implementación Python Paso a Paso
   - 5.1 Dependencias y Entorno
   - 5.2 Módulo de Ingesta
   - 5.3 Agentes LangGraph
   - 5.4 Construcción del Grafo RDF
   - 5.5 Script Principal de Orquestación
6. Conversión de Algoritmos Visuales a Texto Estructurado
   - 6.1 Algoritmo IHC (ASCO/CAP 2023)
   - 6.2 Algoritmos ISH Dual-Probe Grupos 1–5
   - 6.3 Algoritmo de Scoring Completo (Rakha 2026)
7. Consideraciones de Diseño y Limitaciones
8. Referencias

Anexo A – Ontología HER2 con Métricas Fractales (Markdown)

Anexo B – Guía Integrada de Guías y Consensos HER2 (Markdown)

---

1. Introducción y Motivación

El sistema **DigPatho** persigue la clasificación asistida de biopsias histológicas para cáncer de mama, con énfasis en la determinación del estado HER2 mediante análisis computacional de imágenes de corte completo (*Whole Slide Images*, WSI). La integración de métricas fractales multiescala —dimensión fractal de capacidad D_0, dimensión de

información D_1, entropía multifractal, lacunaridad— con los criterios clínicos estándar definidos por las guías internacionales exige una representación formal del conocimiento capaz de soportar razonamiento, inferencia y consulta semántica. El grafo de conocimiento (KG) es la estructura idónea para esa representación.

El presente documento describe el **pipeline completo** para construir ese KG a partir de los documentos fuente adjuntos. El pipeline emplea modelos de lenguaje de gran escala (LLM) accedidos por API como motor de extracción semántica, y el framework **LangGraph** para orquestar el flujo de agentes especializados. El grafo resultante se serializa en formato **RDF/Turtle** compatible con ontologías estándar (SNOMED-CT, NCIt, LOINC, WHO/ISUP).

La propuesta sigue los principios de **Clean Architecture**: separación entre capa interna de lógica de dominio (entidades, relaciones, reglas de inferencia) y capa de infraestructura (acceso a API, I/O de archivos, almacenamiento de triplas). Esto garantiza extensibilidad, testabilidad y mantenibilidad a largo plazo.

---

2. Arquitectura General del Pipeline

El pipeline se organiza en cinco fases encadenadas, implementadas como un grafo de estados en LangGraph:

```
┌──────────────────────────────────────────────────────────────────┐
│                      PIPELINE HER2-KG                            │
│                                                                  │
│  [DOCS]──►[INGEST]──►[EXTRACT]──►[RESOLVE]──►[BUILD]──►[VALIDATE]
│                                                          |       |
│                                                   [TTL/OWL] [SPARQL]
└──────────────────────────────────────────────────────────────────┘
```

Descripción de cada nodo:

- **INGEST**: Lectura, segmentación (*chunking*) y metadatado de documentos fuente (Markdown y PDF).
- **EXTRACT**: Agente LLM que extrae entidades (conceptos médicos, métricas fractales, terapias) y relaciones semánticas desde cada chunk.
- **RESOLVE**: Agente de desambiguación que mapea términos extraídos a URIs canónicas de ontologías estándar (NCIt, SNOMED-CT, LOINC).
- **BUILD**: Construcción del grafo de triplas RDF a partir de entidades y relaciones resueltas.
- **VALIDATE**: Validación de consistencia mediante reglas SPARQL y razonador OWL (opcional).

El estado global del grafo LangGraph mantiene las siguientes claves:

```python
class PipelineState(TypedDict):
    documents: List[Document]        # chunks con metadatos
    raw_extractions: List[dict]      # salida cruda del agente EXTRACT
    resolved_entities: List[dict]    # entidades con URI canónica
    triples: List[tuple]             # (sujeto, predicado, objeto) RDF
    validation_report: dict          # resultado de validación
    errors: List[str]                # errores acumulados
```

3. Fuentes Documentales Integradas

El pipeline procesa los siguientes documentos fuente, con sus respectivos roles epistemológicos:

ID	Documento	Organización	Año	Rol en el KG
D1	*Compilación de guías y consensos en lenguaje fractal*	DigPatho (interno)	2025	Mapeo fractal↔clínico; ejemplo borrador de ontología
D2	*International Expert Consensus Recommendations for HER2 Reporting*	Rakha et al. / Modern Pathology	2026	Categorías HER2-low/ultralow; algoritmo scoring; QA; IA
D3	*Reporting Template for Biomarker Testing – Breast (v1.6.0.0)*	College of American Pathologists (CAP)	Marzo 2025	Template de reporte; categorías IHC 0/0+/1+/2+/3+; ISH grupos 1–5
D4	*ASCO-CAP HER2 Guideline Update – Supplement*	ASCO/CAP	2023	Metodología de búsqueda; bibliografía de referencia
D5	*ASCO-CAP HER2 Guideline Update – Teaching Presentation*	Wolff et al. / ASCO-CAP	2023	Algoritmos en diapositivas; recomendaciones afirmadas
D6	*ASCO-CAP HER2 Guideline Update – Summary of Recommendations*	Wolff et al. / ASCO-CAP	2023	Tabla estructurada de todas las recomendaciones
D7	*ASCO-CAP HER2 Guideline Update – Algorithms (Figuras 1–6)*	Wolff et al. / ASCO-CAP	2023	Algoritmos de decisión IHC y ISH en formato visual

---

4. Componentes del Pipeline

4.1 Ingesta y Preprocesamiento de Documentos

Los documentos fuente se ingresan como archivos Markdown (`.md`) o texto extraído de PDF. El módulo de ingesta realiza:

1. **Segmentación semántica**: división por secciones clínicas identificadas mediante expresiones regulares (encabezados Markdown, títulos de algoritmos, tablas).
2. **Metadatado automático**: cada chunk recibe metadatos de fuente (documento, sección, página estimada, tipo de contenido: `algorithm | criteria | recommendation | qa | fractal_mapping`).
3. **Normalización**: eliminación de artefactos de extracción PDF, unificación de separadores, conversión de tablas a formato estructurado JSON.

El tamaño de chunk recomendado es de 400–600 tokens con un solapamiento (*overlap*) del 15% para preservar contexto en bordes de sección. Para tablas y algoritmos, se mantiene el chunk completo sin solapamiento.

4.2 Extracción de Entidades y Relaciones mediante LLM

El agente **EXTRACT** envía cada chunk al LLM (se recomienda `claude-sonnet-4-6` por su capacidad de razonamiento estructurado y bajo costo por token) con un prompt de sistema especializado que instruye al modelo para devolver JSON estructurado con el siguiente esquema:

```json
{
  "entities": [
    {
      "id": "e001",
      "label": "HER2-Low",
      "type": "ClinicalCategory",
      "definition": "IHC score 1+ OR IHC 2+/ISH negative",
      "source_quote": "HER2-low was defined as an IHC score 1+ or an IHC score
      "candidate_uri": "NCIt:C173790"
    }
  ],
  "relations": [
    {
      "subject_id": "e001",
      "predicate": "eligibleFor",
      "object_id": "e002",
      "confidence": 0.97,
      "evidence": "DB-04 and DB-06 trials"
    }
  ]
}
```

El prompt de sistema incluye:

- Lista de tipos de entidad válidos (ver Sección Ontología en Anexo A).
- Lista de predicados válidos.
- Instrucción explícita de devolver **únicamente JSON** sin Markdown ni preámbulo.
- Ejemplos de pocos disparos (*few-shot*) para entidades fractales y clínicas.

4.3 Construcción del Grafo con LangGraph

LangGraph orquesta el flujo mediante un **StateGraph** con nodos funcionales. Cada nodo es una función Python pura que toma el estado global y retorna una actualización parcial del mismo. Las aristas condicionales permiten derivar el flujo según errores o necesidad de revisión humana (*human-in-the-loop*).

```
        ┌─[ingest_node]
        │
        ▼
[extract_node] ── error? ──▶ [error_handler]
        │
        ▼
[resolve_node] ── ambiguous? ──▶ [human_review]
        │
        ▼
[build_graph_node]
        │
        ▼
[validate_node] ── inconsistent? ──▶ [repair_node]
        │
        ▼
[serialize_node]
        │
        ▼
      [END]
```

4.4 Serialización RDF/OWL y Almacenamiento

El grafo final se serializa en **RDF/Turtle** (`.ttl`) utilizando la biblioteca `rdflib`. Se definen los siguientes *namespaces*:

```turtle
@prefix her2: <http://digpatho.sinc.unl.edu.ar/ontology/her2#> .
@prefix frac: <http://digpatho.sinc.unl.edu.ar/ontology/fractal#> .
@prefix ncit: <http://ncicb.nci.nih.gov/xml/owl/EVS/Thesaurus.owl#> .
@prefix snomed: <http://snomed.info/id/> .
@prefix loinc: <http://loinc.org/rdf#> .
@prefix owl: <http://www.w3.org/2002/07/owl#> .
@prefix rdfs: <http://www.w3.org/2000/01/rdf-schema#> .
```

El archivo TTL resultante puede cargarse directamente en un triple-store (Apache Jena Fuseki, Oxigraph) para consultas SPARQL, o en Protégé para inspección visual y adición de axiomas OWL.

4.5 Validación y Control de Calidad

La validación comprende dos niveles:

Nivel estructural (SPARQL ASK): verificación de que toda entidad con `rdf:type her2:ClinicalCategory` tiene al menos un predicado `her2:hasIHCScore` o `her2:hasISHCriteria`. Verificación de que no existen nodos huérfanos.

Nivel semántico (reglas de dominio): un conjunto de consultas SPARQL codifica las reglas clínicas fundamentales. Por ejemplo:

- Si `?tumor her2:hasIHCScore her2:Score3Plus`, entonces debe existir `?tumor her2:hasStatus her2:Positive`.
- Si `?tumor her2:hasIHCScore her2:Score2Plus` y NO `?tumor her2:hasISHResult her2:Amplified`, entonces `?tumor her2:hasStatus her2:Negative` con categoría `her2:HER2Low`.

- Si `?metric frac:hasDimensionD0 ?d0` y `?d0 > 1.8` y `?tumor her2:hasIHCScore her2:Score0`, se genera una alerta de inconsistencia fractal-clínica.

---

5. Implementación Python Paso a Paso

5.1 Dependencias y Entorno

```bash
# Crear entorno virtual
python -m venv venv_her2kg
source venv_her2kg/bin/activate

# Instalar dependencias
pip install langgraph langchain anthropic rdflib owlready2 \
            pypdf2 python-dotenv pydantic rich tqdm
```

Archivo `requirements.txt`:

```
langgraph>=0.2.0
langchain>=0.3.0
langchain-anthropic>=0.2.0
anthropic>=0.40.0
rdflib>=7.0.0
owlready2>=0.46
pypdf2>=3.0.0
python-dotenv>=1.0.0
pydantic>=2.0.0
rich>=13.0.0
tqdm>=4.0.0
```

Archivo `.env`:

```
ANTHROPIC_API_KEY=sk-ant-...
HER2_KG_MODEL=claude-sonnet-4-6
HER2_KG_OUTPUT_DIR=./output
HER2_KG_DOCS_DIR=./docs
```

5.2 Módulo de Ingesta

```python
```

```python
# internal/ingestion/document_loader.py

from dataclasses import dataclass, field
from pathlib import Path
from typing import List, Optional
import re


@dataclass
class DocumentChunk:
    """Unidad atómica de procesamiento del pipeline."""
    chunk_id: str
    source_doc: str
    section: str
    content: str
    content_type: str  # 'algorithm' | 'criteria' | 'recommendation' | 'fractal
    page_ref: Optional[int] = None
    metadata: dict = field(default_factory=dict)


CONTENT_TYPE_PATTERNS = {
    'algorithm': re.compile(r'(?i)(algorithm|flow|decision|step\s+\d)', re.IGNO
    'criteria': re.compile(r'(?i)(IHC\s+[0-9+]+|ISH|ratio|signals/cell|score)',
    'recommendation': re.compile(r'(?i)(recommend|should|must|guideline)', re.I
    'fractal_mapping': re.compile(r'(?i)(fractal|lacun|dimension|D0|D1|multifra
    'qa': re.compile(r'(?i)(quality|control|validation|QA|EQA|proficiency)', re
}


def detect_content_type(text: str) -> str:
    """Detecta el tipo de contenido predominante en un chunk."""
    scores = {k: len(p.findall(text)) for k, p in CONTENT_TYPE_PATTERNS.items()
    if max(scores.values()) == 0:
        return 'general'
    return max(scores, key=scores.get)


def load_markdown_document(path: Path, chunk_size: int = 500, overlap: int = 75
    """
    Carga un documento Markdown y lo segmenta en chunks semánticos.
    Preserva bloques de tabla y código completos sin dividirlos.
    """
    chunks = []
    text = path.read_text(encoding='utf-8')

    # Dividir por encabezados de sección
    sections = re.split(r'\n(#{1,3}\s+.+)\n', text)

    current_section = 'Introducción'
    chunk_counter = 0

    for i, segment in enumerate(sections):
        if re.match(r'#{1,3}\s+', segment):
            current_section = segment.strip('# ').strip()
            continue
```

```
        # Para tablas y algoritmos: mantener bloque completo
        if '|' in segment or re.search(r'```', segment):
            chunk_id = f"{path.stem}_c{chunk_counter:04d}"
            chunks.append(DocumentChunk(
                chunk_id=chunk_id,
                source_doc=path.name,
                section=current_section,
                content=segment.strip(),
                content_type=detect_content_type(segment),
                metadata={'is_table_or_code': True}
            ))
            chunk_counter += 1
            continue

        # Texto libre: dividir en ventanas con overlap
        words = segment.split()
        pos = 0
        while pos < len(words):
            window = words[pos:pos + chunk_size]
            chunk_text = ' '.join(window)
            if len(chunk_text.strip()) < 50:
                pos += chunk_size - overlap
                continue
            chunk_id = f"{path.stem}_c{chunk_counter:04d}"
            chunks.append(DocumentChunk(
                chunk_id=chunk_id,
                source_doc=path.name,
                section=current_section,
                content=chunk_text,
                content_type=detect_content_type(chunk_text),
            ))
            chunk_counter += 1
            pos += chunk_size - overlap

    return chunks
```

5.3 Agentes LangGraph

```python
```

```python
# internal/agents/extraction_agent.py

import json
import re
from typing import Any, Dict
from anthropic import Anthropic

client = Anthropic()

EXTRACT_SYSTEM_PROMPT = """Eres un experto en patología oncológica y ontologías
Tu tarea es extraer entidades y relaciones semánticas de fragmentos de document
sobre el receptor HER2 en cáncer de mama.

TIPOS DE ENTIDAD VÁLIDOS:
- ClinicalCategory: categoría clínica HER2 (Positive, Negative, Low, Ultralow,
- IHCScore: puntuación IHC (Score0, Score0Plus, Score1Plus, Score2Plus, Score3P
- ISHGroup: grupo ISH 1–5 con sus criterios numéricos
- TherapeuticAgent: agente terapéutico (trastuzumab, trastuzumab-deruxtecan, et
- ClinicalTrial: ensayo clínico (DESTINY-Breast04, DESTINY-Breast06, DAISY, etc
- QualityMeasure: medida de control de calidad o aseguramiento
- FractalMetric: métrica fractal (DimensionD0, DimensionD1, Lacunarity, Multifr
- PathologicalFeature: característica patológica (ArchitecturalComplexity, Tumo
- Biomarker: biomarcador (HER2, ER, PgR, Ki67)
- Guideline: guía clínica (ASCO_CAP_2023, CAP_2025, ESMO_2023)
- Assay: ensayo diagnóstico (VentanaHER2_4B5, HercepTest, etc.)

PREDICADOS VÁLIDOS:
- implies: (IHCScore) → (ClinicalCategory)
- requiresReflexTest: (IHCScore) → (Assay)
- eligibleFor: (ClinicalCategory) → (TherapeuticAgent)
- associatedWith: (FractalMetric) → (PathologicalFeature)
- represents: (FractalMetric) → (ClinicalCategory o PathologicalFeature)
- definedIn: (ClinicalCategory) → (ClinicalTrial o Guideline)
- hasQualityRequirement: (Assay) → (QualityMeasure)
- increasesLikelihood: (PathologicalFeature) → (ClinicalCategory)
- inconsistentWith: para alertas fractal-clínicas

INSTRUCCIÓN CRÍTICA: Devuelve ÚNICAMENTE un objeto JSON válido.
Sin texto adicional, sin bloques ```json```, sin explicaciones."""

FEW_SHOT_EXAMPLE = """
EJEMPLO DE ENTRADA:
"HER2-ultralow was defined as faint or barely perceptible, incomplete membrane
in >0% to ≤10% of tumor cells (IHC score 0+/with membrane staining).
T-DXd has shown benefit in HR-positive HER2-ultralow metastatic breast cancer."

EJEMPLO DE SALIDA:
{
  "entities": [
    {"id": "e1", "label": "HER2-Ultralow", "type": "ClinicalCategory",
     "definition": "IHC 0+ with faint/incomplete staining in >0% to ≤10% of tum
     "candidate_uri": "NCIt:C173791"},
    {"id": "e2", "label": "IHC Score 0+", "type": "IHCScore",
     "definition": "Faint/barely perceptible incomplete membrane staining ≤10%
     "candidate_uri": "NCIt:C173789"},
    {"id": "e3", "label": "Trastuzumab Deruxtecan", "type": "TherapeuticAgent",
```

```
      "definition": "Antibody-drug conjugate targeting HER2 surface protein",
      "candidate_uri": "NCIt:C155379"}
  ],
  "relations": [
    {"subject_id": "e2", "predicate": "implies", "object_id": "e1", "confidence
     "evidence": "DESTINY-Breast06 trial definition"},
    {"subject_id": "e1", "predicate": "eligibleFor", "object_id": "e3", "confid
     "evidence": "DB-06, HR-positive metastatic setting"}
  ]
}
"""


def extract_entities_and_relations(chunk_content: str, source_doc: str) -> dict
    """
    Llama al LLM para extraer entidades y relaciones de un chunk de texto.
    Retorna el JSON parseado o un dict de error.
    """
    user_message = f"""Documento fuente: {source_doc}

{FEW_SHOT_EXAMPLE}

FRAGMENTO A PROCESAR:
{chunk_content}

Extrae entidades y relaciones del fragmento anterior según las instrucciones de

    response = client.messages.create(
        model="claude-sonnet-4-6",
        max_tokens=2000,
        system=EXTRACT_SYSTEM_PROMPT,
        messages=[{"role": "user", "content": user_message}]
    )

    raw_text = response.content[0].text.strip()

    # Limpiar posibles bloques de código residuales
    raw_text = re.sub(r'^```(?:json)?\s*', '', raw_text)
    raw_text = re.sub(r'\s*```$', '', raw_text)

    try:
        return json.loads(raw_text)
    except json.JSONDecodeError as e:
        return {"error": str(e), "raw": raw_text, "entities": [], "relations":
```

python

```python
# internal/agents/resolution_agent.py

# Tabla de mapeo manual curada para términos HER2 de alta frecuencia
# En producción, esta tabla se amplía con llamadas a la API de BioPortal o NCIt

CANONICAL_URIS = {
    # IHC Scores
    "HER2 Score 0": "NCIt:C173786",
    "HER2 Score 0+": "NCIt:C173787",
    "HER2 Score 1+": "NCIt:C173788",
    "HER2 Score 2+": "NCIt:C173789",
    "HER2 Score 3+": "NCIt:C173790",
    # Clinical Categories
    "HER2-Positive": "NCIt:C68748",
    "HER2-Negative": "NCIt:C68749",
    "HER2-Low": "NCIt:C173791",
    "HER2-Ultralow": "NCIt:C173792",
    "HER2-Null": "NCIt:C173793",
    "HER2-Equivocal": "NCIt:C173794",
    # ISH Groups
    "ISH Group 1": "NCIt:C173795",
    "ISH Group 2": "NCIt:C173796",
    "ISH Group 3": "NCIt:C173797",
    "ISH Group 4": "NCIt:C173798",
    "ISH Group 5": "NCIt:C173799",
    # Therapies
    "Trastuzumab": "NCIt:C1647",
    "Trastuzumab Deruxtecan": "NCIt:C155379",
    "Pertuzumab": "NCIt:C64636",
    # Fractal Metrics
    "Fractal Dimension D0": "NCIt:C25730",
    "Fractal Dimension D1": "NCIt:C25731",
    "Lacunarity": "NCIt:C173800",
    "Multifractal Spectrum": "NCIt:C173801",
    # Pathological Features
    "Architectural Complexity": "NCIt:C19754",
    "Tumor Heterogeneity": "NCIt:C16947",
    "HER2 Gene Amplification": "NCIt:C116178",
    "HER2 Protein Overexpression": "NCIt:C44573",
    # Biomarkers
    "ERBB2": "NCIt:C17382",
    "CEP17": "NCIt:C173802",
    "ER": "NCIt:C17687",
    "PgR": "NCIt:C17043",
    "Ki67": "NCIt:C17203",
}

SNOMED_URIS = {
    "Invasive Breast Carcinoma": "snomed:413448000",
    "Ductal Carcinoma In Situ": "snomed:399935008",
    "Metastatic Breast Cancer": "snomed:408643008",
    "HER2 Protein": "snomed:442478000",
    "Immunohistochemistry": "snomed:117299004",
    "In Situ Hybridization": "snomed:404217000",
}
```

```python
def resolve_entity_uri(label: str, candidate_uri: str = None) -> str:
    """
    Resuelve la URI canónica de una entidad.
    Prioridad: (1) tabla curada, (2) candidato del LLM, (3) URI local.
    """
    # Búsqueda exacta en tabla curada
    if label in CANONICAL_URIS:
        return CANONICAL_URIS[label]

    # Búsqueda parcial (case-insensitive)
    label_lower = label.lower()
    for key, uri in CANONICAL_URIS.items():
        if key.lower() in label_lower or label_lower in key.lower():
            return uri

    # Usar candidato del LLM si tiene formato válido
    if candidate_uri and re.match(r'^(NCIt:|snomed:|loinc:)', candidate_uri):
        return candidate_uri

    # Generar URI local
    safe_label = re.sub(r'[^a-zA-Z0-9_]', '_', label)
    return f"her2:{safe_label}"
```

5.4 Construcción del Grafo RDF

```python
```

```python
# internal/graph/rdf_builder.py

from rdflib import Graph, Namespace, URIRef, Literal, RDF, RDFS, OWL, XSD
from typing import List


HER2_NS = Namespace("http://digpatho.sinc.unl.edu.ar/ontology/her2#")
FRAC_NS = Namespace("http://digpatho.sinc.unl.edu.ar/ontology/fractal#")
NCIT_NS = Namespace("http://ncicb.nci.nih.gov/xml/owl/EVS/Thesaurus.owl#")
SNOMED_NS = Namespace("http://snomed.info/id/")
LOINC_NS = Namespace("http://loinc.org/rdf#")


def build_rdf_graph(resolved_entities: List[dict], relations: List[dict]) -> Gr
    """
    Construye el grafo RDF a partir de entidades resueltas y relaciones.
    """
    g = Graph()
    g.bind("her2", HER2_NS)
    g.bind("frac", FRAC_NS)
    g.bind("ncit", NCIT_NS)
    g.bind("snomed", SNOMED_NS)
    g.bind("loinc", LOINC_NS)
    g.bind("owl", OWL)
    g.bind("rdfs", RDFS)

    # Mapa de id_local → URIRef para construcción de relaciones
    uri_map = {}

    for entity in resolved_entities:
        uri = _resolve_to_uriref(entity.get('resolved_uri', entity.get('candida
        uri_map[entity['id']] = uri

        # Tipo RDF
        entity_type = entity.get('type', 'Concept')
        type_uri = HER2_NS[entity_type]
        g.add((uri, RDF.type, type_uri))

        # Etiqueta
        g.add((uri, RDFS.label, Literal(entity['label'], lang='en')))

        # Definición
        if entity.get('definition'):
            g.add((uri, RDFS.comment, Literal(entity['definition'], lang='en'))

        # Equivalencia con ontología externa
        if entity.get('resolved_uri', '').startswith('NCIt:'):
            ncit_id = entity['resolved_uri'].replace('NCIt:', '')
            g.add((uri, OWL.equivalentClass, NCIT_NS[ncit_id]))

    # Añadir relaciones
    for rel in relations:
        subj = uri_map.get(rel.get('subject_id'))
        obj = uri_map.get(rel.get('object_id'))
        if subj and obj:
            predicate = HER2_NS[rel['predicate']]
```

```
            g.add((subj, predicate, obj))

            # Anotar confianza como literal
            if rel.get('confidence'):
                conf_node = URIRef(f"{subj}_{rel['predicate']}_{obj}_conf")
                g.add((conf_node, HER2_NS.confidence, Literal(rel['confidence']
                g.add((conf_node, HER2_NS.evidence, Literal(rel.get('evidence',

    return g


def _resolve_to_uriref(uri_str: str, label: str) -> URIRef:
    """Convierte un string de URI a URIRef."""
    if uri_str.startswith('NCIt:'):
        return NCIT_NS[uri_str.replace('NCIt:', '')]
    elif uri_str.startswith('snomed:'):
        return SNOMED_NS[uri_str.replace('snomed:', '')]
    elif uri_str.startswith('her2:'):
        return HER2_NS[uri_str.replace('her2:', '')]
    else:
        safe_label = label.replace(' ', '_').replace('/', '_').replace('+', 'Pl
        return HER2_NS[safe_label]


def add_fractal_clinical_rules(g: Graph) -> Graph:
    """
    Añade las reglas de mapeo fractal-clínico al grafo RDF.
    Estas reglas codifican las correspondencias del documento D1.
    """
    rules = [
        # D0 alto → Arquitectura compleja → asociado con HER2 positivo
        (HER2_NS.HighDimensionD0, RDFS.subClassOf, HER2_NS.FractalMetric),
        (HER2_NS.HighDimensionD0, RDFS.label, Literal("High Fractal Dimension D
        (HER2_NS.HighDimensionD0, HER2_NS.represents, HER2_NS.ArchitecturalComp
        (HER2_NS.ArchitecturalComplexity, HER2_NS.associatedWith, HER2_NS.HER2_

        # Lacunaridad baja → tejido denso → asociado con IHC 3+
        (HER2_NS.LowLacunarity, HER2_NS.represents, HER2_NS.DenseTissue),
        (HER2_NS.DenseTissue, HER2_NS.associatedWith, HER2_NS.IHC_Score3Plus),

        # Lacunaridad alta → tejido poroso → asociado con IHC 0
        (HER2_NS.HighLacunarity, HER2_NS.represents, HER2_NS.PorousTissue),
        (HER2_NS.PorousTissue, HER2_NS.associatedWith, HER2_NS.IHC_Score0),

        # Delta-alfa alto (multifractalidad) → heterogeneidad espacial alta
        (HER2_NS.HighMultifractalSpread, HER2_NS.represents, HER2_NS.SpatialHet
        (HER2_NS.SpatialHeterogeneity, HER2_NS.associatedWith, HER2_NS.Intratum
        (HER2_NS.IntratumoralHeterogeneity, HER2_NS.triggers, HER2_NS.Additiona

        # Inconsistencia: D0 alto + IHC 0 → alerta
        (HER2_NS.HighD0_IHC0_Inconsistency, RDF.type, HER2_NS.ClinicalAlert),
        (HER2_NS.HighD0_IHC0_Inconsistency, RDFS.label,
         Literal("Fractal-Clinical Inconsistency: High D0 with IHC 0", lang='en
        (HER2_NS.HighD0_IHC0_Inconsistency, HER2_NS.requires, HER2_NS.Pathologi
    ]
```

```python
    for triple in rules:
        g.add(triple)

    return g


def serialize_graph(g: Graph, output_path: str, format: str = 'turtle') -> None
    """Serializa el grafo RDF al formato especificado."""
    g.serialize(destination=output_path, format=format)
    print(f"[OK] Grafo serializado en: {output_path} ({len(g)} triplas)")
```

5.5 Script Principal de Orquestación

```python
```

```python
# main_pipeline.py

import os
from pathlib import Path
from typing import Annotated, TypedDict
from langgraph.graph import StateGraph, END
from langgraph.graph.message import add_messages
from dotenv import load_dotenv
from tqdm import tqdm
from rich.console import Console

from internal.ingestion.document_loader import load_markdown_document, Document
from internal.agents.extraction_agent import extract_entities_and_relations
from internal.agents.resolution_agent import resolve_entity_uri
from internal.graph.rdf_builder import build_rdf_graph, add_fractal_clinical_ru

load_dotenv()
console = Console()


class PipelineState(TypedDict):
    """Estado global del grafo LangGraph."""
    documents: list
    raw_extractions: list
    resolved_entities: list
    all_relations: list
    rdf_graph: object
    errors: list


# ── Nodos del pipeline ──────────────────────────────────────────────

def ingest_node(state: PipelineState) -> dict:
    """Carga y segmenta todos los documentos del directorio docs/."""
    docs_dir = Path(os.getenv('HER2_KG_DOCS_DIR', './docs'))
    all_chunks = []

    for md_file in docs_dir.glob('*.md'):
        console.print(f"[cyan]Ingesting:[/cyan] {md_file.name}")
        chunks = load_markdown_document(md_file)
        all_chunks.extend(chunks)
        console.print(f"  → {len(chunks)} chunks generados")

    console.print(f"\n[bold green]Total chunks:[/bold green] {len(all_chunks)}"
    return {"documents": [c.__dict__ for c in all_chunks]}


def extract_node(state: PipelineState) -> dict:
    """Extrae entidades y relaciones de cada chunk mediante LLM."""
    raw_extractions = []
    errors = list(state.get('errors', []))

    chunks = state['documents']
    for chunk in tqdm(chunks, desc="Extracting"):
        result = extract_entities_and_relations(
            chunk_content=chunk['content'],
```

```
            source_doc=chunk['source_doc']
        )
        result['chunk_id'] = chunk['chunk_id']
        result['section'] = chunk['section']

        if 'error' in result:
            errors.append(f"Chunk {chunk['chunk_id']}: {result['error']}")

        raw_extractions.append(result)

    return {"raw_extractions": raw_extractions, "errors": errors}


def resolve_node(state: PipelineState) -> dict:
    """Resuelve URIs canónicas para todas las entidades extraídas."""
    resolved_entities = []
    all_relations = []

    seen_labels = {}  # deduplicación por label

    for extraction in state['raw_extractions']:
        for entity in extraction.get('entities', []):
            label = entity.get('label', '')
            if label in seen_labels:
                # Actualizar ID local para mapeo de relaciones
                entity['resolved_uri'] = seen_labels[label]
                continue

            resolved_uri = resolve_entity_uri(
                label=label,
                candidate_uri=entity.get('candidate_uri', '')
            )
            entity['resolved_uri'] = resolved_uri
            seen_labels[label] = resolved_uri
            resolved_entities.append(entity)

        # Preservar relaciones con chunk de origen
        for rel in extraction.get('relations', []):
            rel['source_chunk'] = extraction.get('chunk_id', 'unknown')
            all_relations.append(rel)

    console.print(f"[bold green]Entidades únicas:[/bold green] {len(resolved_en
    console.print(f"[bold green]Relaciones totales:[/bold green] {len(all_relat

    return {"resolved_entities": resolved_entities, "all_relations": all_relati


def build_graph_node(state: PipelineState) -> dict:
    """Construye el grafo RDF e incorpora las reglas fractales."""
    g = build_rdf_graph(
        resolved_entities=state['resolved_entities'],
        relations=state['all_relations']
    )
    g = add_fractal_clinical_rules(g)
    console.print(f"[bold green]Triplas RDF generadas:[/bold green] {len(g)}")
    return {"rdf_graph": g}
```

```python
def serialize_node(state: PipelineState) -> dict:
    """Serializa el grafo a TTL y JSON-LD."""
    output_dir = Path(os.getenv('HER2_KG_OUTPUT_DIR', './output'))
    output_dir.mkdir(parents=True, exist_ok=True)

    g = state['rdf_graph']
    serialize_graph(g, str(output_dir / 'her2_knowledge_graph.ttl'), 'turtle')
    serialize_graph(g, str(output_dir / 'her2_knowledge_graph.jsonld'), 'json-l

    # Reporte de errores
    if state.get('errors'):
        error_file = output_dir / 'pipeline_errors.txt'
        error_file.write_text('\n'.join(state['errors']))
        console.print(f"[yellow]Errores registrados en:[/yellow] {error_file}")

    return {}


# ── Construcción del grafo LangGraph ──────────────────────────────────────

def build_pipeline() -> StateGraph:
    """Construye y compila el grafo de flujo LangGraph."""
    workflow = StateGraph(PipelineState)

    workflow.add_node("ingest", ingest_node)
    workflow.add_node("extract", extract_node)
    workflow.add_node("resolve", resolve_node)
    workflow.add_node("build_graph", build_graph_node)
    workflow.add_node("serialize", serialize_node)

    workflow.set_entry_point("ingest")
    workflow.add_edge("ingest", "extract")
    workflow.add_edge("extract", "resolve")
    workflow.add_edge("resolve", "build_graph")
    workflow.add_edge("build_graph", "serialize")
    workflow.add_edge("serialize", END)

    return workflow.compile()


if __name__ == "__main__":
    console.print("[bold blue]═══ Pipeline HER2 Knowledge Graph ═══[/bold blue]

    pipeline = build_pipeline()

    initial_state: PipelineState = {
        "documents": [],
        "raw_extractions": [],
        "resolved_entities": [],
        "all_relations": [],
        "rdf_graph": None,
        "errors": []
    }
```

```
    final_state = pipeline.invoke(initial_state)

    console.print("\n[bold green]Pipeline completado exitosamente.[/bold green]
    console.print(f"Errores: {len(final_state.get('errors', []))}")
```

---

6. Conversión de Algoritmos Visuales a Texto Estructurado

Los documentos fuente (especialmente D5, D6 y D7) contienen algoritmos representados como diagramas de flujo. A continuación se presentan sus representaciones textuales estructuradas, directamente utilizables por el agente de extracción.

6.1 Algoritmo IHC (ASCO/CAP 2023)

Descripción: Clasificación HER2 basada en inmunohistoquímica (IHC) del componente invasivo.

Precondición: Ensayo IHC validado sobre componente invasivo del carcinoma de mama. Controles de batch y controles en portaobjeto muestran tinción apropiada.

Árbol de decisión:

```
ENTRADA: Resultado de tinción IHC del componente invasivo

NODO-1: ¿La tinción es circunferencial completa, intensa y en >10% de células
tumorales?
  → SÍ → RESULTADO: IHC 3+ (Positivo)
  → NO → continuar

NODO-2: ¿La tinción es completa, de intensidad débil a moderada, en >10% de
células tumorales?
  → SÍ → RESULTADO: IHC 2+ (Equívoco) → ACCIÓN: Ordenar test de reflujo ISH
(mismo espécimen) o nueva prueba (nuevo espécimen si disponible, IHC o ISH)
  → NO → continuar

NODO-3: ¿La tinción es incompleta, apenas perceptible/tenue, en >10% de
células tumorales?
  → SÍ → RESULTADO: IHC 1+ (Negativo)
  → NO → continuar

NODO-4: ¿No hay tinción observable? O ¿La tinción es incompleta, tenue/apenas
perceptible y en ≤10% de células tumorales?
  → SÍ → RESULTADO: IHC 0 (Negativo)
    SUB-NODO 4a: ¿Hay tinción de membrana?
      → NO → SUBCATEGORÍA: IHC 0/sin tinción de membrana (HER2-Null)
      → SÍ (tenue/incompleta ≤10%) → SUBCATEGORÍA: IHC 0+/con tinción de
membrana (HER2-Ultralow)

NOTA CLÍNICA (pie de página obligatorio en reporte):
"Pacientes con cáncer de mama HER2 IHC 1+ o IHC 2+/ISH no amplificado pueden
ser
elegibles para tratamiento dirigido a niveles no amplificados/no
sobreexpresados de HER2
(trastuzumab deruxtecan). Los resultados IHC 0 no otorgan elegibilidad
actualmente."

PATRONES INUSUALES (clasificar como IHC 2+ Equívoco):
- Tinción moderada a intensa pero incompleta (basolateral o lateral)
- Tinción circunferencial intensa en ≤10% de células tumorales
(heterogeneidad)
- Tinción citoplasmática abundante que oscurece intensidad de membrana
```

Relaciones KG derivadas:

- `IHC_Score3Plus` → `implies` → `HER2_Positive`
- `IHC_Score2Plus` → `requiresReflexTest` → `ISH_DualProbe`
- `IHC_Score1Plus` → `implies` → `HER2_Negative`
- `IHC_Score1Plus` → `subsetOf` → `HER2_Low`
- `IHC_Score0Plus` → `implies` → `HER2_Negative`
- `IHC_Score0Plus` → `subsetOf` → `HER2_Ultralow`
- `IHC_Score0` → `subsetOf` → `HER2_Null`
- `HER2_Low` → `eligibleFor` → `TrastuzumabDeruxtecan` (entorno metastásico)
- `HER2_Ultralow` → `eligibleFor` → `TrastuzumabDeruxtecan` (HR+, metastásico)
- `HER2_Null` → `notEligibleFor` → `TrastuzumabDeruxtecan`

6.2 Algoritmos ISH Dual-Probe Grupos 1–5

Descripción: Evaluación de amplificación génica HER2 por hibridización in situ con sonda dual (HER2/CEP17).

Definición de grupos:

Grupo	Ratio HER2/CEP17	Señales HER2/célula	Resultado directo
1	⩾ 2.0	⩾ 4.0	ISH Positivo
2	⩾ 2.0	< 4.0	Requiere workup adicional
3	< 2.0	⩾ 6.0	Requiere workup adicional
4	< 2.0	⩾ 4.0 y < 6.0	Requiere workup adicional
5	< 2.0	< 4.0	ISH Negativo

Workup para Grupo 2 (ratio ⩾2.0, señales <4.0):

```
ACCIÓN: Evaluar IHC en secciones del mismo tejido usado para ISH.

SI IHC = 3+ → HER2 Positivo
SI IHC = 2+ → Re-recuento ISH por observador ciego (⩾20 células, zona IHC
2+):
  SI re-recuento cambia categoría ISH → Adjudicar por procedimientos internos
  SI se mantiene ratio ⩾2.0 y señales <4.0 → HER2 Negativo (con comentario-A)
SI IHC = 0 o 1+ → HER2 Negativo (con comentario-A)

COMENTARIO-A: Evidencia limitada sobre eficacia de terapia anti-HER2 en esta
minoría de
casos. Si IHC no es 3+, se recomienda considerar el espécimen como HER2
negativo.
```

Workup para Grupo 3 (ratio <2.0, señales ⩾6.0):

```
ACCIÓN: Evaluar IHC en secciones del mismo tejido usado para ISH.

SI IHC = 3+ → HER2 Positivo
SI IHC = 2+ → Re-recuento ISH por observador ciego (⩾20 células):
  SI se mantiene ratio <2.0 y señales ⩾6.0 → HER2 Positivo
  SI cambia categoría → Adjudicar por procedimientos internos
SI IHC = 0 o 1+ → HER2 Negativo (con comentario-B)

COMENTARIO-B: Datos insuficientes sobre eficacia anti-HER2 con ratio <2.0 sin
sobreexpresión proteíca. Con IHC 0 o 1+ concurrent, considerar HER2 negativo.
```

Workup para Grupo 4 (ratio <2.0, señales ⩾4.0 y <6.0):

```
ACCIÓN: Evaluar IHC en secciones del mismo tejido usado para ISH.

SI IHC = 3+ → HER2 Positivo
SI IHC = 2+ → Re-recuento ISH por observador ciego (≥20 células):
  SI se mantiene ratio <2.0 y señales ≥4.0 y <6.0 → HER2 Negativo (con
comentario-C)
  SI cambia categoría → Adjudicar por procedimientos internos
SI IHC = 0 o 1+ → HER2 Negativo (con comentario-C)

COMENTARIO-C: Incierto si pacientes con ≥4.0 y <6.0 señales/célula y ratio
<2.0 se
benefician de terapia anti-HER2 sin sobreexpresión (IHC 3+). Si resultado
cerca del
umbral, alta probabilidad de resultado diferente al repetir. Cuando IHC no es
3+,
considerar HER2 negativo sin pruebas adicionales en el mismo espécimen.
```

Criterios de rechazo ISH:

- Controles no son como se esperaba
- No se pueden identificar al menos dos áreas de tumor invasivo
- ▎25% de señales no son calificables por señales débiles
- ▎10% de señales ocurren sobre citoplasma
- Resolución nuclear deficiente
- Autofluorescencia intensa
- En todos los casos anteriores: reportar como **Indeterminado**

6.3 Algoritmo de Scoring Completo (Rakha 2026)

Descripción: Sistema de scoring HER2 IHC comprehensivo integrando intensidad, circunferencialidad y porcentaje (basado en Figura 2 de Rakha et al., 2026).

```
DIMENSIONES DE EVALUACIÓN:
  (A) INTENSIDAD: Fuerte | Moderada | Débil | Tenue
  (B) CIRCUNFERENCIALIDAD: Completa | Incompleta
  (C) PORCENTAJE: >10% | ≤10% de células tumorales invasivas

TABLA DE DECISIÓN (Intensidad × Circunferencialidad × Porcentaje →
Score/Categoría):

  Fuerte + Completa + >10%   → Score 3+ → HER2-Positivo
  Fuerte + Completa + ≤10%   → Score 2+ → HER2-Equívoco
  Fuerte + Incompleta + >10% → Score 2+ → HER2-Equívoco
  Fuerte + Incompleta + ≤10% → Score 1+ → HER2-Low

  Moderada + Completa + >10%   → Score 2+ → HER2-Equívoco
  Moderada + Completa + ≤10%   → Score 2+ → HER2-Equívoco
  Moderada + Incompleta + >10% → Score 2+ → HER2-Equívoco
  Moderada + Incompleta + ≤10% → Score 1+ → HER2-Low

  Débil + Completa + >10%   → Score 2+ → HER2-Equívoco
  Débil + Completa + ≤10%   → Score 1+ → HER2-Low
  Débil + Incompleta + >10% → Score 1+ → HER2-Low
  Débil + Incompleta + ≤10% → Score 0+ → HER2-Ultralow

  Tenue + Completa + >10%   → Score 1+ → HER2-Low
  Tenue + Completa + ≤10%   → Score 0+ → HER2-Ultralow
  Tenue + Incompleta + >10% → Score 1+ → HER2-Low
  Tenue + Incompleta + ≤10% → Score 0+ → HER2-Ultralow

  Sin tinción de membrana    → Score 0  → HER2-Null

REGLA DE MAGNIFICACIÓN (práctica):
  Tinción visible a objetivo ×10 → intensidad débil
  Visible a ×20 → intensidad débil a moderada
  Visible a ×40 (apenas perceptible) → intensidad tenue
  Visible a bajo aumento (coincide con control 3+) → intensidad
fuerte/moderada fuerte

REGLA DE TUMOR HETEROGÉNEO:
  SI hay distintas zonas con diferentes intensidades:
    → El score final se asigna según la zona de mayor score
    → Comentar el % de células por cada nivel de score
```

---

7. Consideraciones de Diseño y Limitaciones

Sobre la arquitectura LangGraph. LangGraph permite implementar ciclos de retroalimentación y revisión humana en el pipeline. Para casos de producción, se recomienda añadir un nodo `human_review` accionado cuando la confianza media de extracción sea inferior a 0.75, o cuando el agente de resolución no encuentre URI canónica para más del 30% de las entidades de un chunk.

Sobre la calidad del LLM como extractor. Los LLM son extractores no deterministas. Las variaciones entre llamadas pueden generar inconsistencias en la nomenclatura de entidades. Se recomienda: (1) usar temperatura cero (`temperature=0`) en todas las

llamadas de extracción; (2) implementar caché de resultados (p. ej., con `langchain.cache`); (3) ejecutar al menos dos pasadas y resolver inconsistencias por votación mayoritaria.

Sobre las categorías emergentes HER2-low y ultralow. Las guías son explícitas en señalar que la distinción entre IHC 0 (null) y IHC 0+ (ultralow) es el punto de mayor variabilidad interobservador en patología humana, con tasas de discordancia del 35–40% en estudios multicéntricos (Rakha et al., 2026; Wu et al., 2025). El KG debe representar esta incertidumbre inherente mediante predicados de confianza cuantificada y notas de ambigüedad.

Sobre la integración fractal. Las equivalencias fractal-clínicas del documento D1 son propuestas exploratorias del equipo DigPatho, no recomendaciones de guías clínicas validadas. En el KG, estas relaciones deben marcarse con el predicado `her2:proposedEquivalence` (en lugar de `owl:equivalentClass`) y anotarse con la fuente `DigPatho_Internal_2025`. El pipeline de validación debe tratar estas relaciones como hipótesis a confirmar, no como verdades definitivas.

Sobre el uso de ontologías externas. Los códigos NCIt utilizados en este documento son estimaciones razonadas basadas en el rango de IDs asignados a conceptos HER2 en el NCI Thesaurus. Antes de publicar o federar el grafo, se debe verificar cada URI contra la versión vigente de NCIt (https://ncit.nci.nih.gov) y SNOMED CT.

Sobre escalabilidad. Para volúmenes de extracción superiores a 500 chunks, se recomienda paralelizar las llamadas al LLM usando `asyncio` y el cliente asíncrono de Anthropic (`anthropic.AsyncAnthropic`), respetando los límites de tasa (*rate limits*) de la API.

Sobre regulación y uso clínico. Este sistema es de investigación y desarrollo. Cualquier uso en el entorno clínico debe someterse a los procesos de validación definidos por IEC 62304 (software de dispositivos médicos), ISO 13485 (sistemas de gestión de calidad) y las directrices FDA/EMA para Software as a Medical Device (SaMD).

---

8. Referencias

Bardia, A., Hu, X., Dent, R., et al. (2024). Trastuzumab deruxtecan after endocrine therapy in metastatic breast cancer. *New England Journal of Medicine*, *391*(22), 2110–2122. https://doi.org/10.1056/NEJMoa2407086

College of American Pathologists. (2025, marzo). *Reporting template for reporting results of biomarker testing of specimens from patients with carcinoma of the breast* (Version 1.6.0.0). CAP. https://documents.cap.org/protocols/cp-breastbiomarker-22-rf.pdf

Modi, S., Jacot, W., Yamashita, T., et al. (2022). Trastuzumab deruxtecan in previously treated HER2-low advanced breast cancer. *New England Journal of Medicine*, *387*(1), 9–20. https://doi.org/10.1056/NEJMoa2203690

Rakha, E. A., Tan, P. H., Van Bockstal, M. R., et al. (2026). International expert consensus recommendations for HER2 reporting in breast cancer: Focus on HER2-low and ultralow categories. *Modern Pathology*, *39*, 100925. https://doi.org/10.1016/j.modpat.2025.100925

Tarantino, P., Viale, G., Press, M. F., et al. (2023). ESMO expert consensus statements on the definition, diagnosis, and management of HER2-low breast cancer. *Annals of Oncology*, *34*(8), 645–659. https://doi.org/10.1016/j.annonc.2023.05.008

Wolff, A. C., Somerfield, M. R., Dowsett, M., et al. (2023). Human epidermal growth factor receptor 2 testing in breast cancer: ASCO-CAP guideline update. *Archives of Pathology & Laboratory Medicine*, *147*(9), 993–1000. https://doi.org/10.5858/arpa.2023-0950-SA

Wu, S., Shang, J., Li, Z., et al. (2025). Interobserver consistency and diagnostic challenges in HER2-ultralow breast cancer: A multicenter study. *ESMO Open*, *10*, 104127. https://doi.org/10.1016/j.esmoop.2024.104127

Anexo A – Ontología HER2 con Métricas Fractales

A.1 Descripción General

La presente ontología integra el vocabulario médico estándar para el estado HER2 en cáncer de mama con un vocabulario fractal propuesto por el equipo DigPatho. Está diseñada para ser serializada en OWL/RDF y consultada mediante SPARQL.

Namespaces:

- `her2:` → `http://digpatho.sinc.unl.edu.ar/ontology/her2#`
- `frac:` → `http://digpatho.sinc.unl.edu.ar/ontology/fractal#`
- Externas: `ncit:`, `snomed:`, `loinc:`

A.2 Jerarquía de Clases

```
owl:Thing
├── her2:BreastCancerSpecimen
|   ├── her2:InvasiveComponent
|   └── her2:InSituComponent
|
├── her2:HER2Status
|   ├── her2:HER2_Positive          (NCIt:C68748)
|   ├── her2:HER2_Negative
|   |   ├── her2:HER2_Low           (NCIt:C173791)  [IHC 1+ OR 2+/ISH-]
|   |   ├── her2:HER2_Ultralow      [IHC 0+]
|   |   └── her2:HER2_Null          [IHC 0, sin tinción]
|   └── her2:HER2_Equivocal         [IHC 2+, pendiente ISH]
|
├── her2:IHCScore
|   ├── her2:Score3Plus             → her2:HER2_Positive
|   ├── her2:Score2Plus             → her2:HER2_Equivocal
|   ├── her2:Score1Plus             → her2:HER2_Low
|   ├── her2:Score0Plus             → her2:HER2_Ultralow
|   └── her2:Score0                 → her2:HER2_Null
|
├── her2:ISHResult
|   ├── her2:ISH_Group1_Amplified
|   ├── her2:ISH_Group2_LowCopy
|   ├── her2:ISH_Group3_HighCopyLowRatio
|   ├── her2:ISH_Group4_IntermediateCopy
|   └── her2:ISH_Group5_NotAmplified
|
├── her2:StainingPattern
|   ├── her2:Intensity
|   |   ├── her2:StrongIntensity
|   |   ├── her2:ModerateIntensity
|   |   ├── her2:WeakIntensity
|   |   └── her2:FaintIntensity
|   ├── her2:Circumferentiality
```

```
|   |   ├── her2:CompleteCircumferential
|   |   └── her2:IncompleteCircumferential
|   └── her2:PercentageStained
|       ├── her2:MoreThan10Percent
|       └── her2:AtMost10Percent
|
├── her2:TherapeuticAgent
|   ├── her2:Trastuzumab            (NCIt:C1647)
|   ├── her2:TrastuzumabDeruxtecan  (NCIt:C155379)
|   ├── her2:Pertuzumab             (NCIt:C64636)
|   └── her2:TDM1                   (NCIt:C82492)
|
├── her2:ClinicalTrial
|   ├── her2:DESTINY_Breast04
|   ├── her2:DESTINY_Breast06
|   └── her2:DAISY_Trial
|
├── her2:Guideline
|   ├── her2:ASCO_CAP_2023
|   ├── her2:CAP_Biomarker_2025
|   ├── her2:ESMO_2023
|   └── her2:Rakha_International_2026
|
├── her2:QualityMeasure
|   ├── her2:FixationRequirement    [NBF 10%, 6-72h]
|   ├── her2:SectionAgeRequirement  [<6 semanas]
|   ├── her2:ControlRequirement     [rango completo 0, 1+, 2+, 3+]
|   └── her2:EQAParticipation
|
└── frac:FractalMetric              (NCIt:C25730)
    ├── frac:CapacityDimension_D0   [alta → arquitectura compleja]
    ├── frac:InformationDimension_D1[alta → heterogeneidad multifractal]
    ├── frac:Lacunarity             [baja → tejido denso; alta → poroso]
    ├── frac:MultifractalSpread_Da  [alta → variabilidad espacial]
    └── frac:MultiscaleEntropy      [alta → complejidad temporal]
```

A.3 Propiedades de Objeto (Object Properties)

Propiedad	Dominio	Rango	Descripción
`her2:hasIHCScore`	Specimen	IHCScore	Score IHC asignado
`her2:hasISHResult`	Specimen	ISHResult	Resultado ISH
`her2:hasStatus`	Specimen	HER2Status	Estado HER2 final
`her2:implies`	IHCScore	HER2Status	Implicación diagnóstica directa
`her2:requiresReflexTest`	IHCScore	her2:Assay	Test de reflujo requerido

Propiedad	Dominio	Rango	Descripción
`her2:eligibleFor`	HER2Status	TherapeuticAgent	Elegibilidad terapéutica
`her2:notEligibleFor`	HER2Status	TherapeuticAgent	Inelegibilidad terapéutica
`her2:definedIn`	HER2Status	ClinicalTrial	Definición de ensayo
`her2:regulatedBy`	TherapeuticAgent	her2:RegulatoryBody	Aprobación regulatoria
`her2:hasQualityRequirement`	her2:Assay	QualityMeasure	Requisito de calidad
`frac:represents`	FractalMetric	her2:PathologicalFeature	Representación fractal→clínico
`frac:associatedWith`	FractalMetric	HER2Status	Asociación estadística
`frac:proposedEquivalence`	FractalMetric	HER2Status	Equivalencia propuesta (hipótesis)
`frac:inconsistentWith`	FractalMetric + IHCScore	her2:ClinicalAlert	Alerta de inconsistencia

A.4 Propiedades de Datos (Data Properties)

Propiedad	Tipo	Descripción
`her2:ratioHER2CEP17`	xsd:float	Ratio HER2/CEP17 medido
`her2:avgHER2SignalsPerCell`	xsd:float	Señales HER2 promedio/célula
`her2:percentageStained`	xsd:float	% células con tinción
`her2:confidence`	xsd:float	Confianza de extracción (0–1)
`frac:valueD0`	xsd:float	Valor numérico de D0
`frac:valueD1`	xsd:float	Valor numérico de D1
`frac:valueLacunarity`	xsd:float	Valor numérico de lacunaridad
`frac:valueDeltaAlpha`	xsd:float	Rango del espectro multifractal

A.5 Mapeo Fractal ↔ Clínico (tabla de equivalencias propuestas)

Métrica Fractal	Valor Umbral	Hallazgo Clínico Asociado	Correlato IHC/ISH	Referencia
D0 (dimensión de capacidad)	> 1.85	Arquitectura glandular compleja	IHC 2+ o 3+ (probable)	D1 (interno)
D0	< 1.55	Arquitectura simple, tejido homogéneo	IHC 0 o 1+ (probable)	D1 (interno)
Lacunaridad	< 0.15	Tejido denso, gránulos fusionados	IHC 3+ (tinción compacta)	D1 (interno)
Lacunaridad	> 0.60	Tejido poroso, espacios vacuolares	IHC 0 o artefactos	D1 (interno)
Δα (spread multifractal)	> 0.80	Alta variabilidad espacial multiescala	Heterogeneidad intratumoral	D1 (interno)
Entropía multiscala	> 1.50	Complejidad temporal alta	Tumor de alto grado	D1 (interno)
D1 (dimensión de información)	> 1.70	Distribución heterogénea de información	ISH grupos 2–4 (posible)	D1 (interno)

NOTA IMPORTANTE: Todas las equivalencias de esta tabla son **propuestas de investigación** del equipo DigPatho, no recomendaciones clínicas validadas. En el grafo RDF se representan con `frac:proposedEquivalence` y la fuente `DigPatho_Internal_2025`.

A.6 Axiomas OWL Clave (Turtle)

```turtle
```

```
# Clase IHC Score 3+ implica HER2 Positivo (OWL restriction)
her2:Score3Plus rdfs:subClassOf [
    owl:onProperty her2:implies ;
    owl:hasValue her2:HER2_Positive
] .

# HER2-Low es subclase de HER2-Negative
her2:HER2_Low rdfs:subClassOf her2:HER2_Negative .
her2:HER2_Ultralow rdfs:subClassOf her2:HER2_Negative .
her2:HER2_Null rdfs:subClassOf her2:HER2_Negative .

# Disyunción: Positive y Negative son disjuntos
her2:HER2_Positive owl:disjointWith her2:HER2_Negative .

# Elegibilidad T-DXd: Low y Ultralow son elegibles
her2:HER2_Low rdfs:subClassOf [
    owl:onProperty her2:eligibleFor ;
    owl:hasValue her2:TrastuzumabDeruxtecan
] .
her2:HER2_Ultralow rdfs:subClassOf [
    owl:onProperty her2:eligibleFor ;
    owl:hasValue her2:TrastuzumabDeruxtecan
] .

# HER2-Null NO es elegible
her2:HER2_Null rdfs:subClassOf [
    owl:onProperty her2:notEligibleFor ;
    owl:hasValue her2:TrastuzumabDeruxtecan
] .
```

Anexo B – Guía Integrada de Guías y Consensos HER2

B.1 Resumen Ejecutivo de las Fuentes

La clasificación HER2 en cáncer de mama ha experimentado una transformación paradigmática entre 2022 y 2026. El catalizador fue la publicación del ensayo DESTINY-Breast04 (Modi et al., 2022), que demostró beneficio clínico de trastuzumab deruxtecan (T-DXd) en pacientes con tumores HER2-low (IHC 1+ o 2+/ISH negativo). Posteriormente, DESTINY-Breast06 (Bardia et al., 2024) extendió ese beneficio a la categoría HER2-ultralow (IHC 0+, tinción tenue ≤10%). Ambas aprobaciones regulatorias (FDA y EMA, 2025) fuerzan una redefinición operativa del espectro HER2, transformando la binaria "positivo/negativo" en un continuo de cinco categorías clínicamente relevantes.

B.2 Criterios IHC Integrados (todas las guías)

B.2.1 Categoría IHC 3+ → HER2-Positivo

Criterio primario (ASCO/CAP 2023, CAP 2025, Rakha 2026): Tinción de membrana circunferencial completa, de intensidad fuerte/intensa, en más del 10% de las células tumorales invasivas. Visible con objetivo de bajo aumento. Homogénea y contigua.

Patrones inusuales clasificados como 2+ equívoco:

- Tinción circunferencial intensa en ≤10% células (heterogeneidad focal)

- Tinción moderada a intensa pero incompleta (basolateral)

Correlato fractal DigPatho: D0 elevado (>1.85), lacunaridad muy baja (<0.10), patrón de tinción denso y uniforme.

B.2.2 Categoría IHC 2+ → Equívoco (requiere ISH)

Criterio primario (ASCO/CAP 2023): Tinción de membrana completa, de intensidad débil a moderada, en más del 10% de células tumorales invasivas.

Patrones adicionales (CAP 2025, Rakha 2026):

- Tinción moderada completa en cualquier porcentaje
- Tinción moderada a fuerte, incompleta, en >10%
- Tinción fuerte completa en ≤10% (heterogeneidad)
- Tinción citoplasmática abundante que oscurece membrana

Nota magnification: tinción visible a ×10 o ×20, con intensidad moderada. Comparar siempre con control 3+.

Acción: Test ISH de reflujo en el mismo espécimen, o nueva prueba en nuevo espécimen (IHC o ISH).

Correlato fractal DigPatho: D0 intermedio (1.60–1.85), lacunaridad intermedia, heterogeneidad moderada.

B.2.3 Categoría IHC 1+ → Negativo / HER2-Low

Criterio primario (ASCO/CAP 2023): Tinción de membrana incompleta, tenue/apenas perceptible, en más del 10% de células tumorales invasivas.

Patrones adicionales (Rakha 2026):

- Tinción débil completa en ≤10% células
- Tinción débil incompleta en >10% células
- Tinción moderada incompleta en ≤10% células

Magnification: tinción apreciable a ×20, ocasionalmente a ×10. Apenas perceptible a ×40.

Relevancia clínica: elegibilidad para T-DXd en entorno metastásico (DB-04).

Correlato fractal DigPatho: D0 bajo-intermedio (1.50–1.65), lacunaridad moderada.

B.2.4 Categoría IHC 0+ → Negativo / HER2-Ultralow

Criterio (CAP 2025, Rakha 2026, DB-06): Tinción de membrana tenue/apenas perceptible, incompleta, en >0% y ≤10% de células tumorales invasivas.

Magnification: tinción apenas perceptible a ×40, no visible a magnificaciones menores.

Distinción con Score 0: el 0+ tiene *alguna* tinción de membrana detectable; el 0 (null) no tiene ninguna.

Desafío diagnóstico: el 35–40% de casos reportados localmente como IHC 0 son reclasificados como 0+ en revisión central (DB-06). Alta variabilidad interobservador.

Relevancia clínica: elegibilidad para T-DXd en pacientes HR+ con metástasis (DB-06, 2024).

Correlato fractal DigPatho: D0 muy bajo (<1.55), lacunaridad alta (>0.55), textura muy uniforme con mínima complejidad arquitectural.

B.2.5 Categoría IHC 0 → Negativo / HER2-Null

Criterio (todas las guías): Sin tinción de membrana detectable en células tumorales invasivas.

CAP 2025 distingue: reportar explícitamente como "0/sin tinción de membrana" para diferenciar del 0+.

Relevancia clínica: actualmente excluidos de elegibilidad para T-DXd.

Correlato fractal DigPatho: D0 muy bajo (<1.45), lacunaridad máxima (>0.70), patrón casi sin estructura.

B.3 Criterios ISH Integrados (ASCO/CAP 2023)

B.3.1 Definiciones de Grupos ISH

Grupo	Ratio HER2/CEP17	Señales HER2/cel	Resultado base
1	⩾ 2.0	⩾ 4.0	Amplificado (Positivo)
2	⩾ 2.0	< 4.0	Indeterminado → workup
3	< 2.0	⩾ 6.0	Indeterminado → workup
4	< 2.0	⩾ 4.0 y < 6.0	Indeterminado → workup
5	< 2.0	< 4.0	No amplificado (Negativo)

B.3.2 Resolución de Grupos 2–4

Para los grupos 2, 3 y 4, la determinación final requiere correlación con IHC:

- IHC 3+ → HER2 Positivo (en todos los grupos)
- IHC 2+ → Re-recuento ISH por observador ciego (⩾20 células en zona IHC 2+)
- IHC 0 o 1+ → HER2 Negativo con comentario explicativo

Notas UK Guidelines (Rakha 2026): Consideran positivo si ratio ⩾2.0 **O** señales ⩾6.0. Las guías ASCO/CAP requieren ratio ⩾2.0 con señales ⩾4.0, **O** señales ⩾6.0.

B.3.3 Heterogeneidad ISH

Si existe una segunda población de células contiguas con señales HER2 incrementadas y esta población comprende >10% de las células tumorales del portaobjeto: realizar recuento separado de ⩾20 células no superpuestas en esa población y reportarla independientemente.

B.4 Categorías HER2 Emergentes y Terapia ADC

B.4.1 Resumen de Eligibilidad para T-DXd

Categoría	IHC	ISH	Elegibilidad T-DXd	Contexto
HER2-Positive	3+	Amplificado	NO (otras terapias)	Adyuvante y metastásico
HER2-Positive	2+	Amplificado	NO (otras terapias)	
HER2-Low	1+	Negativo	SÍ	Metastásico (DB-04)

Categoría	IHC	ISH	Elegibilidad T-DXd	Contexto
HER2-Low	2+	Negativo	SÍ	Metastásico (DB-04)
HER2-Ultralow	0+	-	SÍ (HR+)	Metastásico (DB-06)
HER2-Null	0	-	NO	Excluidos actualmente

B.4.2 Mecanismo de Acción de T-DXd

T-DXd no requiere señalización oncogénica activa de HER2 para ejercer su efecto. El anticuerpo (trastuzumab) se une a la proteína HER2 superficial y media la internalización del conjugado, liberando el payload citotóxico (inhibidor de topoisomerasa I, deruxtecan) intracelularmente. El payload es permeable a membrana, generando efecto bystander sobre células HER2-negativas adyacentes. Este mecanismo explica la eficacia incluso en HER2-ultralow (con mínima expresión proteíca) y, paradójicamente, en tumores HER2-null en algunos estudios (DAISY: 29.7% tasa de respuesta objetiva en cohorte HER2-null).

B.5 Consideraciones de Control de Calidad (QA)

B.5.1 Preanalíticas

- **Isquemia fría**: < 1 hora desde extirpación hasta fijación
- **Fijador**: formol neutro tamponado al 10%, pH 7.0–7.4
- **Tiempo de fijación**: 6–72 horas (máximo 96h en casos excepcionales)
- **Secciones**: idealmente <6 semanas desde el corte; almacenar a 2–8°C o TA controlada
- **No recomendado**: muestras en decalcificación, aspirados de aguja fina para evaluación de bajo nivel HER2

B.5.2 Analíticas

- **Ensayo preferido**: VENTANA HER2 (4B5) con protocolo bloqueado (FDA). Incubación anticuerpo primario fijada en 12 minutos.
- **Controles obligatorios**: rango completo (0, 1+, 2+, 3+); controles externos en portaobjeto recomendados
- **Líneas celulares de control**: 3+ (SK-BR-3, BT-474), null (MDA-MB-231, MCF-7), 1+ (MDA-MB-175)
- **Tinción no scoreable**: necrosis, células degeneradas, tinción citoplasmática, tinción apical/luminal artefactual, artefactos de borde (*edge artifacts*)

B.5.3 Postanalíticas

- **Score mínimo de células**: ≥100 células invasivas para discriminar 0, 0+, 1+
- **Score ISH**: 20–60 células invasivas
- **Doble revisión**: recomendada para casos marginales (0 vs 0+, 0+ vs 1+)
- **Magnificación para casos difíciles**: ×40 para discriminar IHC 0, 0+, 1+, 2+
- **Comunicación oncólogo-patólogo**: esencial para pacientes potencialmente elegibles para T-DXd
- **Re-testeo**: considerar en enfermedad metastásica o residual; si espécimen original reportó solo "HER2 0" sin distinguir null/ultralow

B.6 Rol de la Inteligencia Artificial en el Scoring HER2

Los algoritmos de IA para scoring HER2 muestran un desempeño que mejora con la puntuación:

- IHC 3+: sensibilidad agrupada 0.97, especificidad 0.99
- IHC 2+: sensibilidad 0.89, especificidad 0.96
- IHC 1+: sensibilidad 0.69, especificidad 0.94 (mayor discordancia en categorías intermedias)

Limitaciones actuales (Rakha 2026):

- La verdad de campo (*ground truth*) para 0+ y 1+ es intrínsecamente inestable por variabilidad interobservador
- Los modelos entrenados solo en 0/3+ no son válidos para el espectro low/ultralow
- Se requiere infraestructura de patología digital (no disponible en todos los centros)
- La supervisión del patólogo sigue siendo obligatoria

Recomendación de consenso: La IA debe ser una herramienta de soporte, no de reemplazo, para el scoring HER2. Su implementación requiere validación específica en cohortes con representación adecuada de HER2-low y ultralow.

B.7 Reporte Estructurado (CAP Template v1.6.0.0, Marzo 2025)

El CAP ha actualizado su plantilla de reporte sinóptico para incluir explícitamente las cinco categorías HER2:

Para IHC HER2:

- Score 0: subcategorías "0/sin tinción de membrana" vs "0+/con tinción de membrana"
- Score 1+, 2+, 3+: con descripción de patrón de tinción
- Heterogeneidad clustered: reporte de % con 3+ y score en zonas no-3+
- **Comentario estandarizado opcional**: explicación de HER2-low y ultralow según DB-04 y DB-06

Para ISH HER2:

- Señales HER2 promedio/célula
- Señales CEP17 promedio/célula
- Ratio HER2/CEP17
- Número de células contadas / número de observadores
- Grupo ISH (1–5) con comentario para grupos 2–4
- Descripción de heterogeneidad si presente

Fin del documento

Este documento fue generado como guía de implementación para el pipeline DigPatho HER2-KG. Versión 1.0 – Abril 2026.